

Лабораторная работа № 1.

Цель: научиться превращать «грязные» текстовые сообщения в структурированные и нормализованные данные, пригодные для дальнейшего анализа.

Ситуация

Команда получает выгрузку пользовательских сообщений из условного интернет-сервиса. В сообщениях встречаются ссылки, номера телефонов, адреса электронной почты, цены, даты, лишние символы, смешение регистра, опечатки и различные формы одних и тех же слов. Необходимо разработать единый конвейер предварительной обработки.

Логика решения

исходное сообщение → извлечение значимых сущностей → очистка → токенизация → удаление стоп-слов → лемматизация → частотный анализ

Задание

1. Загрузить исходный датасет и проверить, какие столбцы и типы данных он содержит.
2. Привести текст к единому регистру, удалить лишние пробелы и повторяющиеся знаки пунктуации.
3. С помощью регулярных выражений находить и отдельно сохранять URL, e-mail, телефонные номера, даты и цены.
4. Обезличить персональные данные, заменяя их маркерами [PHONE], [EMAIL] и т. п.
5. Разбить очищенный текст на токены; удалить стоп-слова и пунктуацию.
6. Выполнить лемматизацию слов.
7. Сформировать для каждого сообщения как минимум поля `clean_text`, `tokens`, `lemmas` и найденные сущности.
8. Построить TOP-20 слов до очистки и после очистки; сравнить результаты.
9. Сохранить обработанный датасет в отдельный CSV-файл.

Что должна сдать команда

- Воспроизводимый скрипт с пояснениями;
- `clean_messages.csv` - обработанный датасет;
- краткий вывод о влиянии очистки и нормализации на данные.

Система оценивания лабораторной №1 — максимум 15 баллов

Критерий	Баллы	Что проверяется
1. Загрузка и первичный анализ данных	1	Датасет корректно загружен; типы данных, пропуски и объём выборки
2. Базовая очистка текста	2	Приведение регистра, удаление лишних пробелов, повторяющейся пунктуации и мусорных символов
3. Извлечение сущностей регулярными выражениями	3	Корректно находятся URL, e-mail, телефоны, даты и цены; результаты сохраняются отдельно
4. Обезличивание данных	2	Телефоны, e-mail и другие сущности заменяются маркерами [PHONE], [EMAIL] и т. п.
5. Токенизация и удаление стоп-слов	1.5	Текст корректно разбит на токены, удалены пунктуация и стоп-слова
6. Лемматизация	1.5	Получены нормальные формы слов, результат сохраняется отдельно
7. Формирование итогового датасета	1	Есть как минимум clean_text, tokens, lemmas и поля с найденными сущностями
8. Частотный анализ	1	Построен TOP-20 слов до и после очистки, результаты корректно сравниваются
9. Сохранение результата	1	Итоговый обработанный датасет сохранён в clean_messages.csv
10. Качество кода и воспроизводимость	1	Код запускается целиком, логично разделён на этапы, нет большого количества ручных замен
Итого	15	

Пример

КУПИТЕ!!! новый ноутбук!!! <https://shop.ru> Цена: 89 990 руб. Тел: +7-999-123-45-67

1. Найденные сущности

URL: <https://shop.ru>
Телефон: +7-999-123-45-67
Цена: 89 990 руб.
E-mail: —
Дата: —

2. После приведения к нижнему регистру и очистки пунктуации

купите новый ноутбук <https://shop.ru> цена 89 990 руб тел +7-999-123-45-67

3. После обезличивания

купите новый ноутбук [URL] цена [PRICE] тел [PHONE]

4. Очищенный текст для дальнейшего анализа

Если служебные сущности убираются из текста:

купите новый ноутбук цена тел

При этом сами сущности сохраняются в отдельных столбцах.

5. Токены

["купите", "новый", "ноутбук", "цена", "тел"]

Если слово тел считать служебным и удалить:

["купите", "новый", "ноутбук", "цена"]

6. После лемматизации

["купить", "новый", "ноутбук", "цена"]

7. Итоговая строка датасета

Например:

Поле	Результат
original_text	КУПИТЕ!!! новый ноутбук!!! https://shop.ru Цена: 89 990 руб. Тел: +7-999-123-45-67
urls	[" https://shop.ru "]
phones	["+7-999-123-45-67"]
emails	[]
dates	[]
prices	["89 990 руб."]

Поле	Результат
anonymized_text	купите новый ноутбук [URL] цена [PRICE] тел [PHONE]
clean_text	купите новый ноутбук цена
tokens	["купите", "новый", "ноутбук", "цена"]
lemmas	["купить", "новый", "ноутбук", "цена"]

То есть вся цепочка на этом примере выглядит так:

КУПИТЕ!!! новый ноутбук!!! <https://shop.ru> Цена: 89 990 руб. Тел: +7-999-123-45-67

↓

извлечение сущностей

↓

URL = <https://shop.ru>

PRICE = 89 990 руб.

PHONE = +7-999-123-45-67

↓

купите новый ноутбук [URL] цена [PRICE] тел [PHONE]

↓

купите новый ноутбук цена

↓

["купите", "новый", "ноутбук", "цена"]

↓

["купить", "новый", "ноутбук", "цена"]